

# Dokumentenzusammenfasser – Erläuterung zur Umsetzung

Phase 2: Erarbeitungs-/Reflexionsphase | Portfolio DLMDSPMLSD01

## Umsetzung

Das in Phase 1 festgelegte Konzept wurde vollständig als lauffähige Anwendung umgesetzt: eine Dash-Weboberfläche zum Hochladen von PDF-Dokumenten und ein separater Microservice, der die Zusammenfassung erstellt. Beide Komponenten laufen als eigene Docker-Container (**dash-app** und **ml-service**) in einem gemeinsamen Netzwerk und lassen sich mit einem einzigen Befehl (**docker compose up**) starten – plattformunabhängig, wie in der Aufgabenstellung gefordert. Für die Zusammenfassung kommt das vortrainierte Modell **facebook/bart-large-cnn** über eine FastAPI-Schnittstelle zum Einsatz. Die Backend-Logik (Dateiprüfung, Textextraktion mit pypdf, Textbereinigung und Aufteilung langer Dokumente) ist bewusst von der Oberfläche getrennt, damit sie unabhängig testbar bleibt.

## Vorgehen in dieser Phase

- Projektstruktur angelegt (app/, ml\_service/, evaluation/, tests/) entlang der im Konzept skizzierten Architektur.
- Dash-Frontend und Backend-Logik implementiert: Upload, Validierung, PDF-Textextraktion, Vorverarbeitung, Ergebnisanzeige.
- Summarization-Microservice mit FastAPI und HuggingFace-Modell umgesetzt (Endpunkte /summarize, /health).
- Docker-Setup für beide Container erstellt und lokal getestet (docker-compose.yml, zwei Dockerfiles).
- 21 Unit-Tests für Dateiprüfung, Textvorverarbeitung, ML-Client und ML-Service-API geschrieben – alle bestehen.
- Modell auf einer Stichprobe von 30 Dokumenten aus cnn\_dailymail bewertet (ROUGE, Verarbeitungszeit, Kompressionsrate).
- Öffentliches GitHub-Repository eingerichtet, Code mit Commit-Historie versioniert und gepusht.

## Modellbewertung

Bewertet wurde facebook/bart-large-cnn auf 30 Dokumenten des cnn\_dailymail-Testdatensatzes (Skript: evaluation/evaluate\_model.py). Da es sich um Nachrichtentexte statt Patentedokumente handelt, zeigen die Werte die technische Leistungsfähigkeit von Modell und Pipeline, nicht die fachliche Eignung für Patentanmeldungen.

| ROUGE-1 (F1) | ROUGE-2 (F1) | ROUGE-L (F1) | Zeit / Dok. | Kompressionsrate |
|--------------|--------------|--------------|-------------|------------------|
| 0,347        | 0,146        | 0,253        | 5,53 s (Ø)  | ≈ 9 %            |

## Code-Dokumentation & Versionsverwaltung

Der gesamte Code ist mit deutschsprachigen Docstrings und Kommentaren versehen, die Entscheidungen (z. B. Trennung von Frontend/Backend, Chunking langer Dokumente) begründen statt nur zu beschreiben, was der Code tut. Die Versionierung erfolgt über Git; das Repository ist öffentlich einsehbar unter:

<https://github.com/NeliDilkova/document-summarizer>